Attention is All you need

Vaswani, Ashish, et al. "Attention is all you need."
Advances in neural information processing systems 30 (2017).

2024.05.09 유하영

Abstarct

단일 Attention mechanism을 사용한 Transformer 모델을 제안

1) 품질이 우수, 병렬성이 뛰어남, 훈련 소요시간 줄어듦
2) English-to-German, English-to-French 번역 작업에서 향상된 성능을 보임.

Introduction

Recurrent neural network의
병렬처리 문제

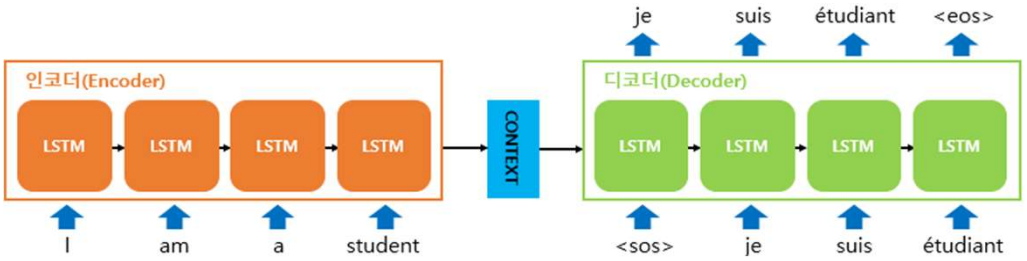

Attention mechanism 제시

long sequence -> 정보손실↑

Encoder and Decoder Stacks

Model architecture

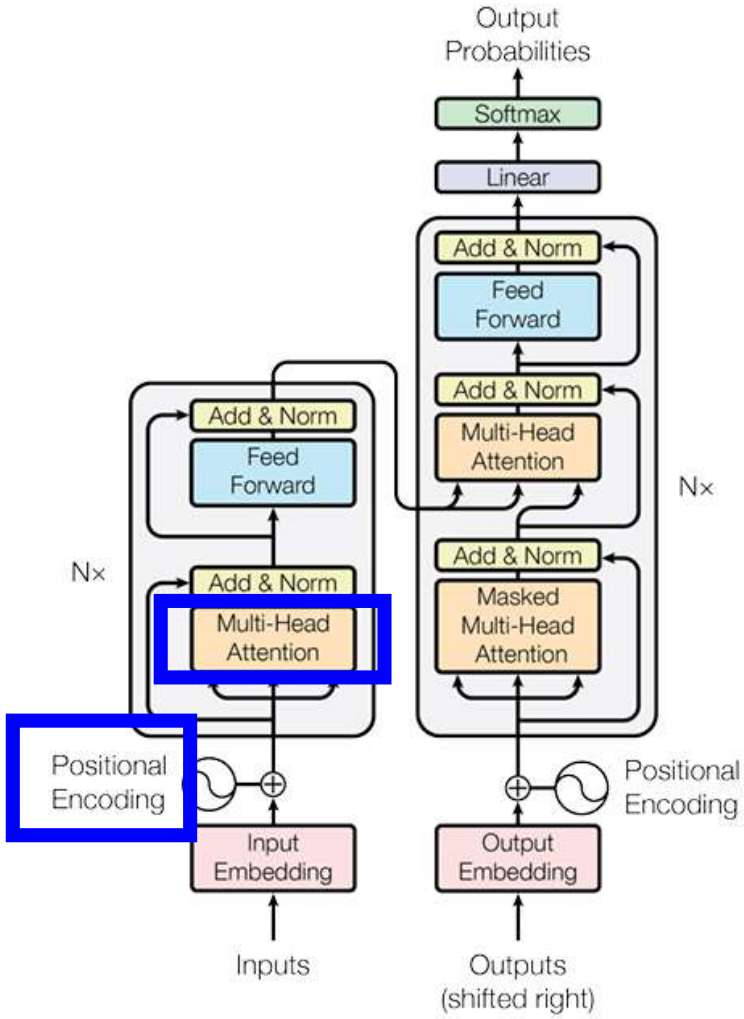

Figure 1: The Transformer - model architecture.

1. Positional Encoding

seq2seq

순차적 처리

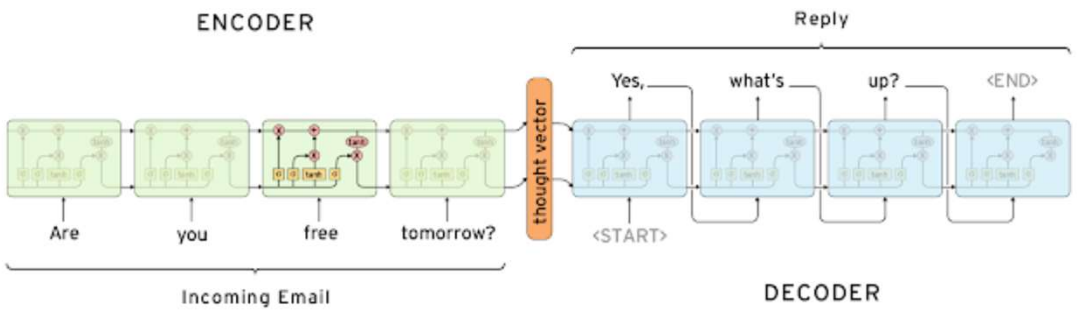

Attention만을 사용하여
인코더와 디코더를 연결시켜보자.

- layer 수를 줄여 연산량을 줄이고
- gradient vanishing 문제를 해결하자

Transformer

병렬 처리

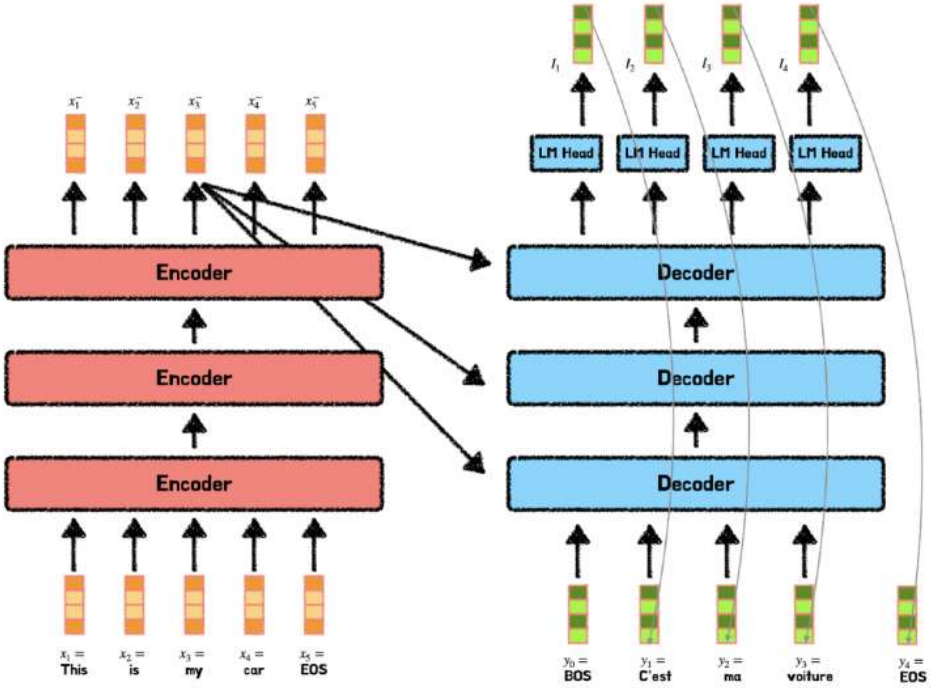

Positional Encoding

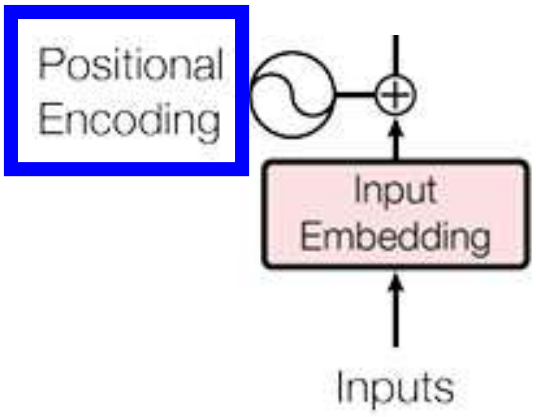

"모델이 상대적 위치에 따라 쉽게 학습할 수 있도록
다음과 같은 함수를 제시한다."

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$

$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

pos : 단어의 위치
i : 차원 인덱스
d : 인코딩 벡터의 차원

https://kazemnejad.com/blog/transformer_architecture_positional_encoding/

https://www.blossominkyung.com/deeplearning/transfomer-positional-encoding

Positional Encoding

규칙 1. 모든 위치 값은 시퀀스 길이나 input 시퀀스와 관계없이
동일한 식별자를 가져야 한다.
(시퀀스 내용이나 길이가 변경되더라도, 위치 임베딩은 동일하게 유지)

규칙 2. 모든 위치 벡터 값은 너무 크면 안된다.

제안 1) 시퀀스 크기에 비례해서 일정하게 커지는 정수값 부과

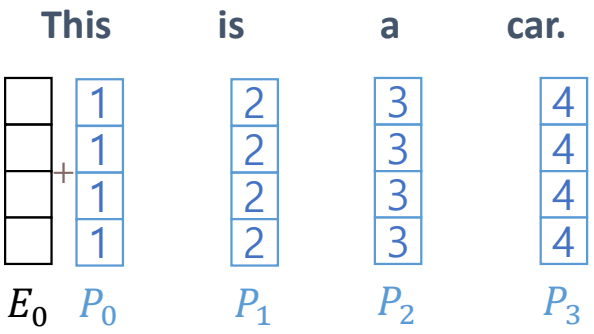

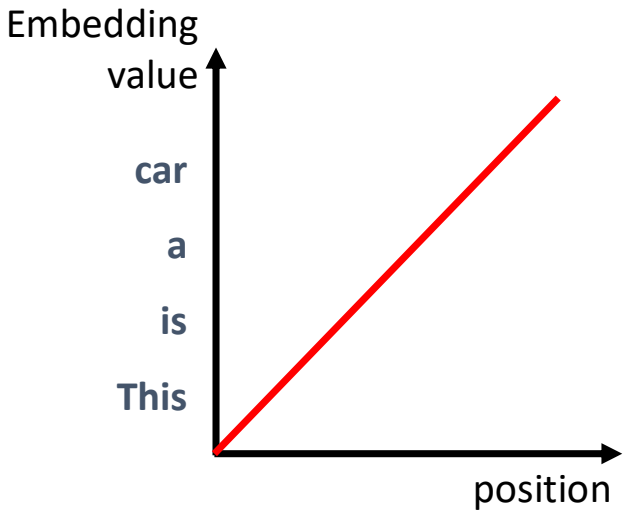

규칙 2 위배 -> 단어의 의미 훼손

Positional Encoding

규칙 1. 모든 위치 값은 시퀀스 길이나 input 시퀀스와 관계없이
동일한 식별자를 가져야 한다.
(시퀀스 내용이나 길이가 변경되더라도, 위치 임베딩은 동일하게 유지)

규칙 2. 모든 위치 벡터 값은 너무 크면 안된다.

제안 2) 0~1 사이의 값으로 정규화 (첫 번째 토큰:0, 마지막 토큰:1, 나머지:1/단어 수)

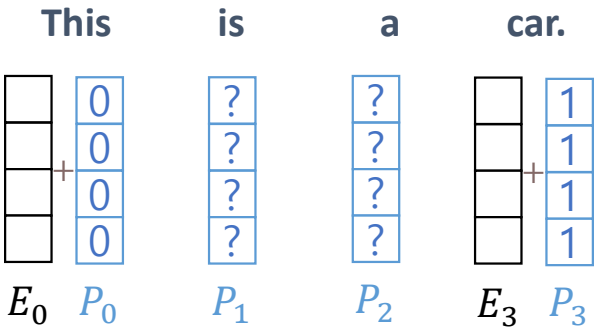

규칙 1 위배

Positional Encoding

규칙 1. 모든 위치 값은 시퀀스 길이나 input 시퀀스와 관계없이
동일한 식별자를 가져야 한다.
(시퀀스 내용이나 길이가 변경되더라도, 위치 임베딩은 동일하게 유지)

규칙 2. 모든 위치 벡터 값은 너무 크면 안된다.

제안 3) **상대적 위치에 따른 위치 인코딩 정보**

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

sin /cos ?

-1~1사이의 값을 갖는 주기함수

(cf. sigmoid 사용?
긴 문장 시퀀스가 주어졌을 시,
위치 벡터 값들의 차이가 없음)

*혼용해서 사용하는 것이 보다 풍부한 학습

Positional Encoding

pos : 단어의 위치
i : 차원 인덱스
d : 인코딩 벡터의 차원

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

문장	:	My	**name**	is	Hayeong
pos	:	0	**1**	2	3

$\boldsymbol{pos = 1}$

$i = 0, \quad d = 4$

P_1

0.8
0.5
0.01
1.0

$i = 0$

$PE_{(1,0)} = \sin(1/10000^{0/4}) \quad \sin(1) \approx 0.8$

$PE_{(1,1)} = \cos(1/10000^{0/4}) \quad \cos(1) \approx 0.5$

$i = 1$

$PE_{(1,2)} = \sin(1/10000^{2/4}) \quad \sin(1/100) \approx 0.01$

$PE_{(1,3)} = \cos(1/10000^{2/4}) \quad \cos(1/100) \approx 1.0$

1. Positional Encoding

128차원 임베딩 벡터에 대하여 위치 인코딩을 통한
< 문장의 시각적 표현 >

[초기 차원]

낮은 주파수
긴 주기

전체 문맥 등
넓은 범위의
의미적 정보파악

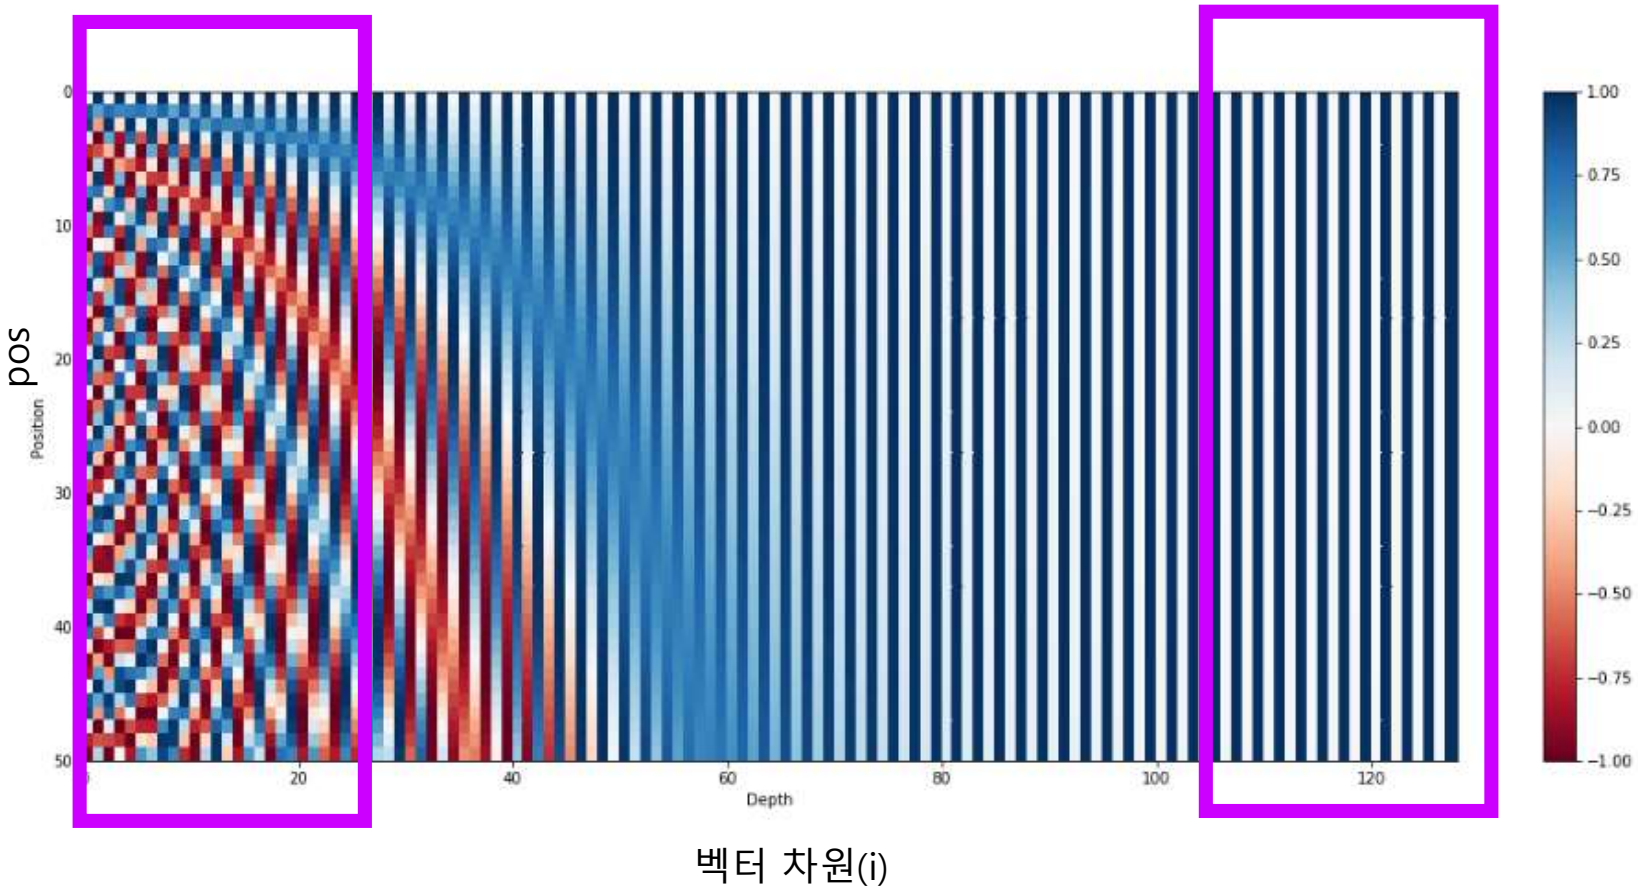

[후기 차원]

높은 주파수
짧은 주기

문법적 특징 등
세밀한 정보파악

벡터 차원(i)

https://kazemnejad.com/blog/transformer_architecture_positional_encoding/

Summation vs **Concat**

My name is Hayeong.

Concat

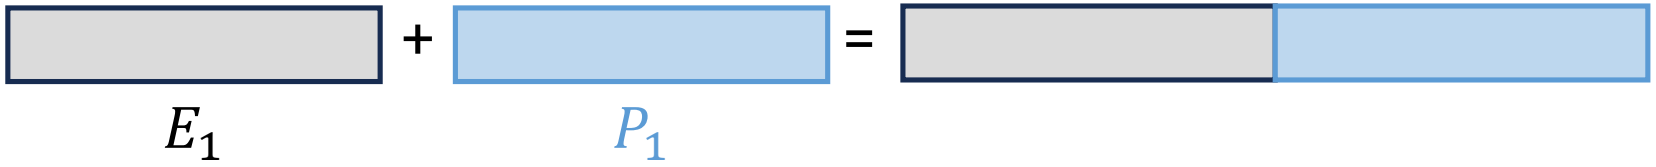

비용문제

Summation

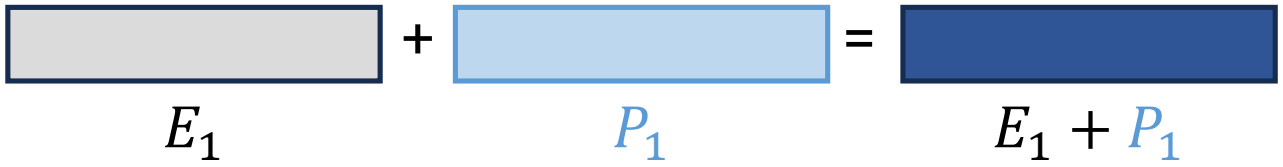

Multi-Head Attention

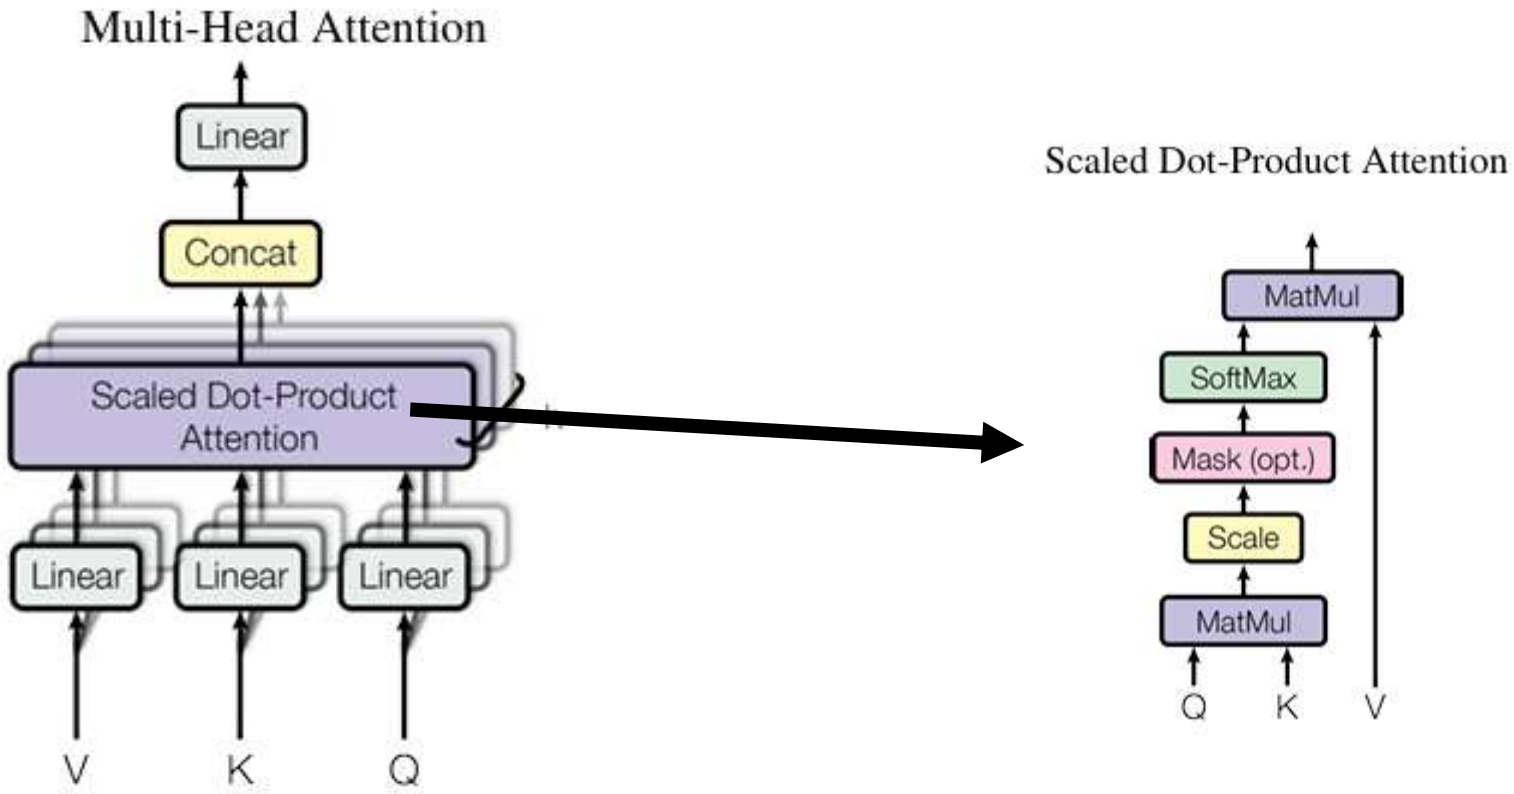

Scaled Dot-Product Attention

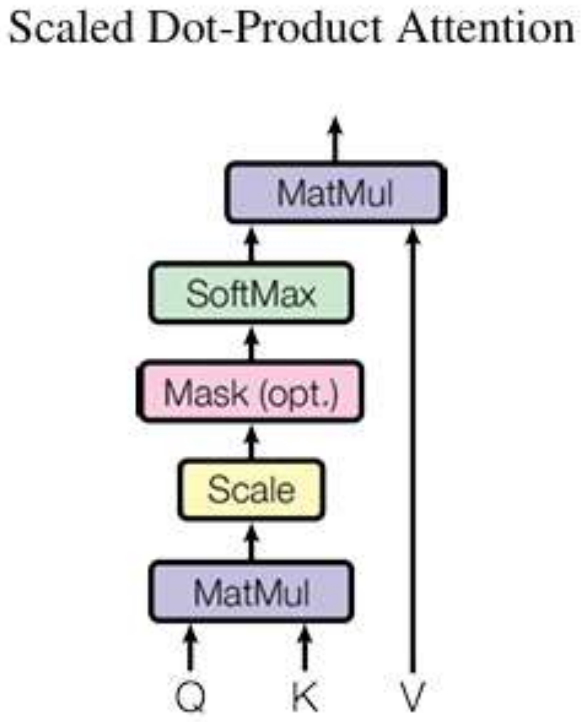

Input sequence

→ 임베딩 행렬로 변환 + PE

→ □ x W^Q, □ x W^K, □ x W^V,

→ Q, K, V

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Q : 모든 입력 벡터
K : 모든 입력 벡터
V : 모든 입력 벡터

Q-K(유사도 파악)
V(가중치 합계 계산/QK의 유사한만큼 V값)

Multi-Head Attention

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, ..., \text{head}_\text{h})W^O$$
$$\text{where head}_\text{i} = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

Which do you like better, coffee or tea? - 문장 타입에 집중하는 어텐션

Which do you like better, coffee or tea? - 명사에 집중하는 어텐션

Which do you like better, coffee or tea? - 관계에 집중하는 어텐션

Which do you like better, coffee or tea? - 감조에 집중하는 어텐션

Self-Attention을 병렬로 h번 학습
다양한 관점에서 정보 수집 위함

3. Add & Norm

Add

- **Residual Connection**

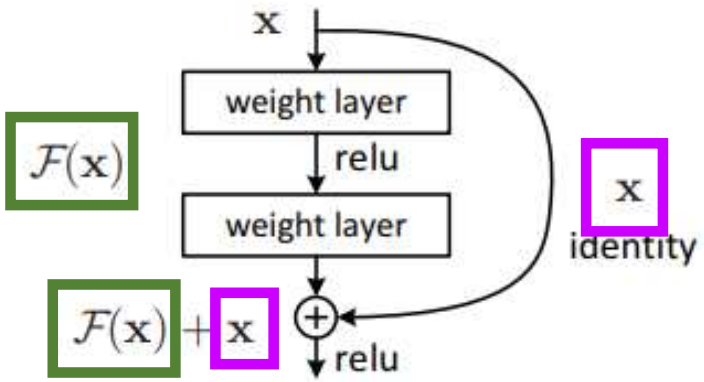

Figure 2. Residual learning: a building block.

$$F(x) + x$$

"shortcut connections" : skipping one or more layers

- 신경망의 깊이가 깊어질 때 발생할 수 있는 성능 저하 문제 완화
  - 그래디언트 소실 문제 완화

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	**21.43**	**5.71**

Error rates on ImageNet validation.

https://arxiv.org/pdf/1512.03385

3. Add & Norm

Add

- **Residual Connection**

$$output = \boldsymbol{Input} + \boldsymbol{Sublayer}(\boldsymbol{Input})$$

(ex. self-attention, FFNN)

$$H(x) = x + Multi-head\ Attention(x)$$

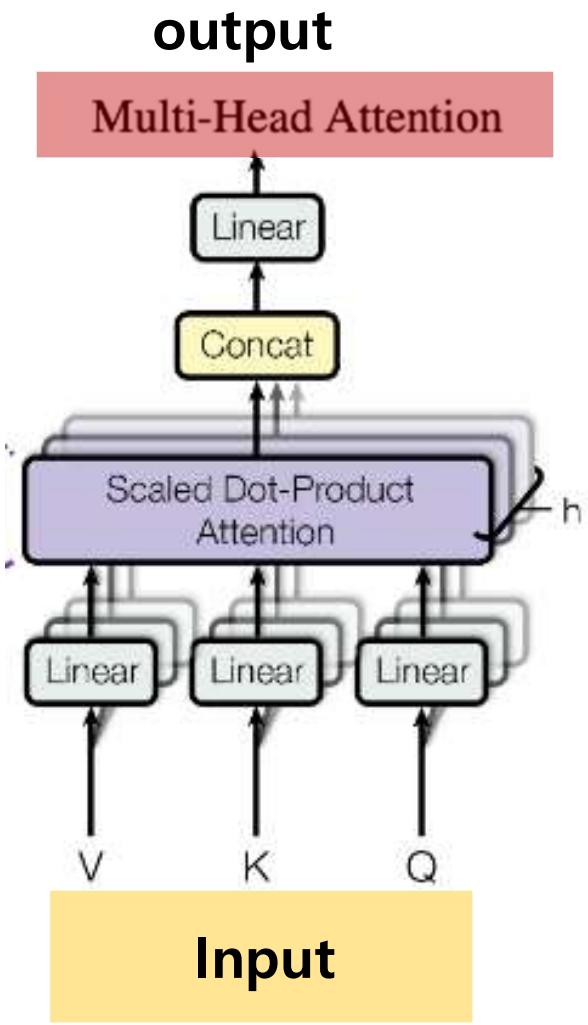

3. Add & Norm

Norm

- Layer Normalization

순차적 데이터 처리나 각 시점(time step)에서
독립적으로 데이터를 처리해야 하는 RNN과 같은 구조에서 사용되는 정규화 방법

$$\boldsymbol{LayerNorm}(x + Sublayer(x))$$

$$LN(\mathbf{z};\boldsymbol{\alpha},\boldsymbol{\beta}) = \frac{(\mathbf{z}-\mu)}{\sigma} \odot \boldsymbol{\alpha} + \boldsymbol{\beta},$$

$$\mu = \frac{1}{D}\sum_{i=1}^{D} z_i, \quad \sigma = \sqrt{\frac{1}{D}\sum_{i=1}^{D}(z_i-\mu)^2},$$

α : 각 요소의 스케일 조정
β : 시프트 조정

https://arxiv.org/pdf/1607.06450

Position-wise FFNN

position-wise fully connected feed-forward network

: 각 Head가 만들어낸 Attention을 치우치지 않게 균등하게 섞는 역할

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

(d_{model}, d_{ff}) — W_1

(N, d_{model}) — x

(d_{ff}, d_{model}) — W_2

$H = \mathrm{ReLU}(W_1 x + b_1)$

입력 벡터를 더 높은 차원의 표현 공간으로 매핑

$z = W_2 H + b_2$

확장된 벡터 H를 다시 원래 차원 d_{model}로 매핑

N : 입력 데이터의 개수
d_{model} : 모델의 차원 수 (512)
d_{ff} : 피드포워드 네트워크의 내부 레이어 차원 수..일반적으로 4배(2048)

5. Applications of Attention in our Model

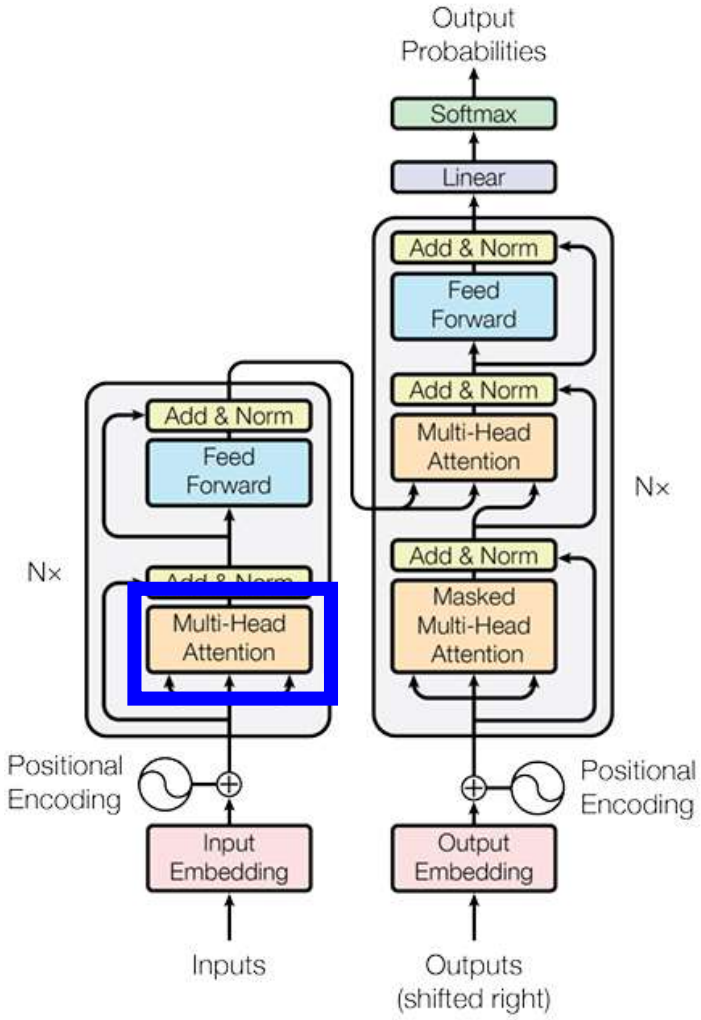

Figure 1: The Transformer - model architecture.

1. self-attention in Encoder

   Q, K, V 모두 Encoder로부터 가져온다.
   (단어들 간의 연관성 학습)

5. Applications of Attention in our Model

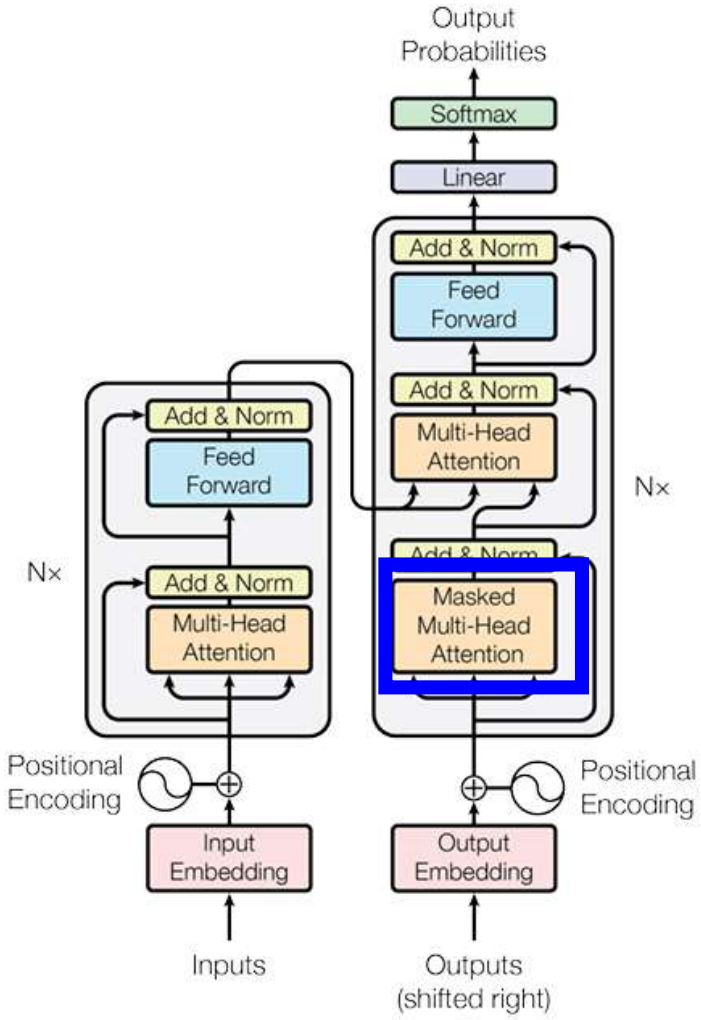

Figure 1: The Transformer - model architecture.

2. self-attention in Decoder (Masked)

미래의 위치에 있는 토큰 정보를 미리 "보지 않도록" 하기 위해 마스킹을 사용

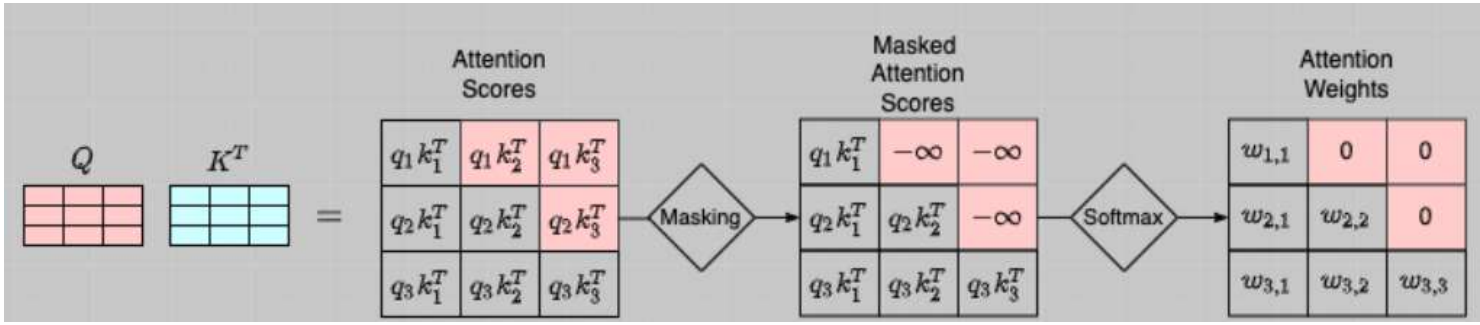

i < j 는
주어진 입력 값이 볼 수 없는 **미래 시점의 입력 값과의 유사도**

➔ 행렬의 대각선 윗부분을 -∞로 변경
➔ softmax를 취하여 Attention Weight를 0으로 만듦
(미래 시점 값 고려 X)

5. Applications of Attention in our Model

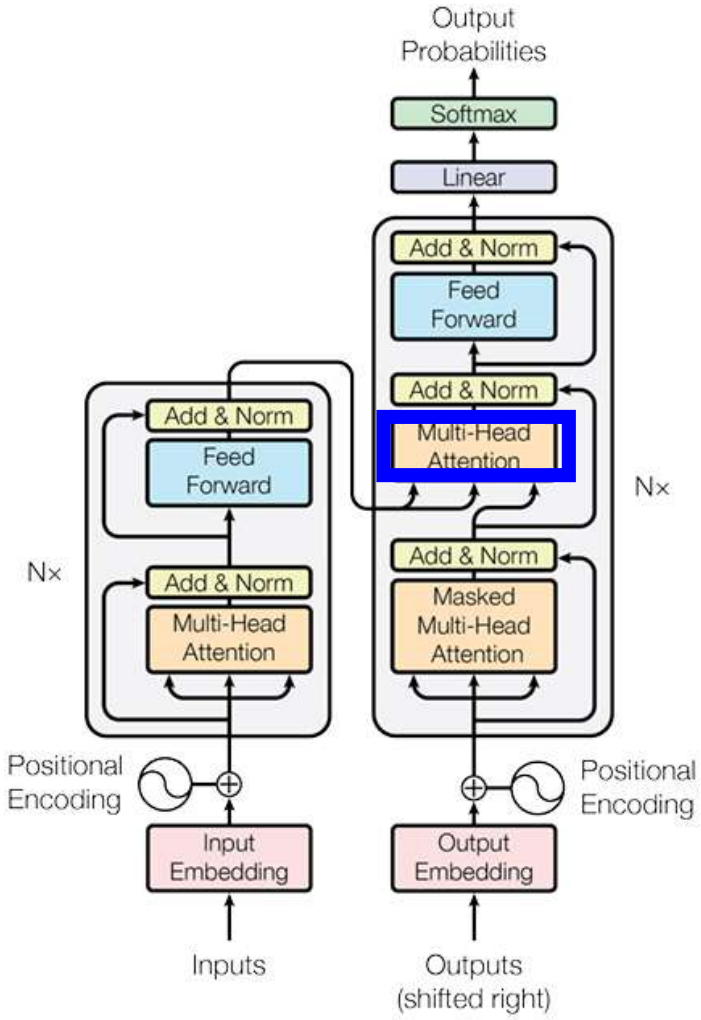

Figure 1: The Transformer - model architecture.

3. Encoder-Decoder attention

Query -> 이전 디코더 레이어에서 가져옴
key, Value -> 인코더의 출력에서 가져옴

seq2seq에서는 context vector을 통해 전체 입력 시퀀스에 대한 정보 통합했음
->
Transformer은 인코더의 K,V 정보를 활용하여 다음 토큰 예측!

Result

Model	BLEU	
	EN-DE	EN-FR
ByteNet [18]	23.75	
Deep-Att + PosUnk [39]		39.2
GNMT + RL [38]	24.6	39.92
ConvS2S [9]	25.16	40.46
MoE [32]	26.03	40.56
Deep-Att + PosUnk Ensemble [39]		40.4
GNMT + RL Ensemble [38]	26.30	41.16
ConvS2S Ensemble [9]	26.36	**41.29**
Transformer (base model)	27.3	38.1
Transformer (big)	**28.4**	**41.8**

어텐션 헤드수 / 어텐션 K 차원 / 어텐션 V 차원

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65
(A)				1	512	512				5.29	24.9	
				4	128	128				5.00	25.5	
				16	32	32				4.91	25.8	
				32	16	16				5.01	25.4	
(B)					16					5.16	25.1	58
					32					5.01	25.4	60
(C)	2									6.11	23.7	36
	4									5.19	25.3	50
	8									4.88	25.5	80
		256			32	32				5.75	24.5	28
		1024			128	128				4.66	26.0	168
			1024							5.12	25.4	53
			4096							4.75	26.2	90
(D)							0.0			5.77	24.6	
							0.2			4.95	25.5	
								0.0		4.67	25.3	
								0.2		5.47	25.7	
(E)	positional embedding instead of sinusoids									4.92	25.7	
big	6	1024	4096	16			0.3		300K	**4.33**	**26.4**	213

학습된 임베딩으로 대체